

Efecto de la visibilidad de un agente virtual en el desempeño y la confianza del usuario en tareas de decisión basadas en reglas

Ney Fred Jiménez Campos

Universidad de Costa Rica, Posgrado en Computación e Informática, PF-3311 — Agentes Virtuales Inteligentes

Resumen

Se evaluó un prototipo Unity con tres condiciones within-subjects: A (sin agente), B (agente conversacional en texto) y C (mismo agente con avatar 3D y voz). Cada participante resolvió seis ítems de decisión basados en reglas por condición, reportando confianza inmediata (escala 1–7) tras cada respuesta.

En este piloto participaron 3 sesiones canónicas (3 con bloques A, B y C completos). La precisión media fue A=66.67%, B=77.78%, C=83.33%. La confianza media (Unity) fue A=5.0, B=5.0, C=5.0. La brecha de calibración (confianza normalizada menos precisión del bloque) fue A=0.0, B=-0.1111, C=-0.1667. Se discuten implicaciones para el diseño de agentes virtuales pedagógicos y las limitaciones de una muestra exploratoria.

Palabras clave: agente virtual; confianza calibrada; diseño within-subjects; LLM; precisión; usabilidad

1. Introducción

Los agentes conversacionales basados en modelos de lenguaje amplio (LLM) se integran cada vez más en interfaces de apoyo a la decisión. Una pregunta abierta es si la presencia visible del agente —avatar y voz— modifica el desempeño objetivo y la confianza subjetiva del usuario frente a la misma asistencia solo textual o sin agente.

Este trabajo reporta un piloto within-subjects en el que cada participante experimenta tres condiciones: sin agente (A), chat con LLM (B) y chat con avatar animado y síntesis de voz (C). Las preguntas de investigación son: (RQ1) ¿difieren los aciertos entre condiciones?; (RQ2) ¿difieren los niveles de confianza?; y (RQ3) ¿cómo varía la calibración entre confianza y precisión?

Las hipótesis exploratorias plantean precisión $C \approx B > A$ (H1), confianza $C > B > A$ (H2) y mayor sobreconfianza en C (H3).

2. Método

Participantes. Adultos mayores de 18 años reclutados de forma abierta. Se analizaron 3 sesiones canónicas; 3 completaron los tres bloques (6+6+6 ítems).

Diseño. Factor within-subjects con tres niveles (A, B, C). Orden de condiciones contrabalanceado según código de participante. Materiales: 18 ítems con reglas y opciones múltiples; confianza 1–7 tras cada respuesta; cuestionarios RAW-TLX y meCUE 2.0 tras cada bloque.

Procedimiento. Sesión en máquina virtual Windows con build Unity standalone. En B y C el participante podía consultar al agente (Gemini 2.5 Flash) con un system prompt

restrictivo que prohíbe revelar la respuesta correcta. En C las respuestas del agente se sintetizan con Azure Speech y lip-sync sobre avatar TTBoyB.

Métricas. Precisión (% aciertos por bloque), confianza media por ítem, brecha de calibración $((\text{confianza}-1)/6 - \text{precisión})$, carga RAW-TLX, métricas de chat (HelpScore, intercambios, filtraciones del modelo) y indicadores de viabilidad (latencia Gemini, éxito TTS, integridad CSV).

Análisis. Estadística descriptiva por condición. Con $n \geq 3$ participantes completos se aplican prueba de Friedman y Wilcoxon pareado post hoc con corrección Bonferroni ($\alpha=0,05$). Los resultados se interpretan como exploratorios.

3. Resultados

La muestra analizada comprendió 3 participantes canónicos (3 con datos completos A–C).

La Tabla 1 resume la precisión (% aciertos) por condición.

Condición A: media 66.67% ($n=3$).

Condición B: media 77.78% ($n=3$).

Condición C: media 83.33% ($n=3$).

La confianza media (escala 1–7, Unity) por condición se muestra en la Tabla 2.

Condición A: media 5.0 ($n=3$).

Condición B: media 5.0 ($n=3$).

Condición C: media 5.0 ($n=3$).

La brecha de calibración se operacionalizó como confianza normalizada $((C-1)/6)$ menos la precisión del bloque.

Condición A: brecha media 0.0 ($n=3$).

Condición B: brecha media -0.1111 ($n=3$).

Condición C: brecha media -0.1667 (n=3).

Las hipótesis exploratorias H1–H3 se evaluaron a partir de las medias grupales observadas.

Ver anexo de inferencia para pruebas Friedman y Wilcoxon post hoc cuando $n \geq 3$.

En condiciones B y C se compararon métricas del agente (Tabla 5).

Comparación exploratoria del agente entre condiciones B (texto) y C (avatar + voz):

HelpScore: media B=67.5 (n=1), media C= (n=0).

Engagement: media B=15.0 (n=1), media C= (n=0).

ChatExchanges: media B=1.0 (n=1), media C= (n=0).

ModelLeaks: media B=0.0 (n=1), media C= (n=0).

Los criterios de viabilidad técnica del piloto se reportan en la Tabla 6.

Inferencia no paramétrica (piloto):

[RQ1]

Inferencia (piloto):

Precisión | Friedman $\chi^2=3.7143$, $p=0.1561$ (n=3)

Post hoc Wilcoxon pareado (p ajustada Bonferroni, 3 comparaciones):

A vs B: $W=0.0000$, $p=0.5000$, $p_{adj}=1.0000$

A vs C: $W=0.0000$, $p=0.5000$, $p_{adj}=1.0000$

B vs C: $W=0.0000$, $p=1.0000$, $p_{adj}=1.0000$

[RQ2 Unity]

Inferencia (piloto):

Confianza Unity | Friedman $\chi^2=\text{nan}$, $p=\text{nan}$ (n=3)

Post hoc Wilcoxon pareado (p ajustada Bonferroni, 3 comparaciones):

A vs B: $W=0.0000$, $p=1.0000$, $p_{adj}=1.0000$

A vs C: $W=0.0000$, $p=1.0000$, $p_{adj}=1.0000$

B vs C: $W=0.0000$, $p=1.0000$, $p_{adj}=1.0000$

[RQ3]

Inferencia (piloto):

Brecha calibración | Friedman $\chi^2=3.7143$, $p=0.1561$ (n=3)

Post hoc Wilcoxon pareado (p ajustada Bonferroni, 3 comparaciones):

A vs B: $W=0.0000$, $p=0.5000$, $p_{adj}=1.0000$

A vs C: $W=0.0000$, $p=0.5000$, $p_{adj}=1.0000$

Tabla 1. Precisión media por condición (% aciertos)

Condición	Media	N
A	66.67	3
B	77.78	3
C	83.33	3




Figura 1. Precisión media por condición

Tabla 2. Confianza media por condición (Unity, 1–7)

Condición	Media	N
A	5.0	3
B	5.0	3
C	5.0	3




Figura 2. Confianza media por condición

Tabla 3. Brecha de calibración por condición

Condición	Brecha	N
A	0.0	3
B	-0.1111	3
C	-0.1667	3




Figura 3. Brecha de calibración

Tabla 5. Métricas del agente (B vs C)

Métrica	Media B	Media C
HelpScore	67.5	
Engagement	15.0	
ChatExchanges	1.0	
ModelLeaks	0.0	

Tabla 6. Viabilidad técnica del piloto

Métrica	Valor
ValidRows	54
TotalRows	54
ValidPct	100.0
Passes95PctRule	1
GeminiPasses90Pct	1
TtsPasses85Pct	1
TotalModelLeaks	0
LeaksPer10Participants	0.0
LeaksPassRule	1

4. Discusión

Los resultados deben interpretarse como exploratorios dado el diseño piloto within-subjects.

Las diferencias entre condiciones A (sin agente), B (chat texto) y C (avatar + voz) se discuten en relación con las hipótesis H1–H3 y la carga cognitiva reportada en Forms.

Limitaciones: tamaño muestral del piloto, generalización y dependencia de la infraestructura (Gemini, Azure TTS) en condiciones B/C.

La comparación B versus C aísla el efecto de la modalidad embodied (avatar + voz) manteniendo constante el contenido del LLM. Los cuestionarios meCUE y RAW-TLX aportan contexto sobre carga y percepción, aunque la

medida primaria de confianza proviene de la escala inmediata en Unity.

Entre las limitaciones figuran el tamaño muestral del piloto, la dependencia de APIs en la nube y la generalización limitada fuera del contexto académico ficticio empleado.

5. Conclusiones

Se documentó el procesamiento de datos de Unity y Forms en tablas reproducibles.

Las figuras adjuntas ilustran medias por condición para precisión, confianza y calibración.

Trabajo futuro: ampliar N, análisis cualitativo de entrevistas y refinamiento del agente.

Referencias

- Lee, J. D., & See, K. A. (2004). Trust in automation: Designing for appropriate reliance. *Human Factors*, 46(1), 50–80.
- Minge, M., & Thüring, M. (2018). meCUE 2.0. *Proceedings of Mensch und Computer 2018*.
- Hart, S. G., & Staveland, L. E. (1988). Development of NASA-TLX. *Advances in Psychology*, 52, 139–183.
- Nielsen, J. (1994). *Usability Engineering*. Morgan Kaufmann.
- Brooke, J. (1996). SUS: A quick and dirty usability scale. *Usability Evaluation in Industry*.