

Universidad de Costa Rica

PROGRAMA DE POSGRADO EN COMPUTACIÓN E INFORMÁTICA

PF-3311 – Agentes Virtuales Inteligentes

ENTREGABLE 1
Propuesta de Agente e Investigación

***Efecto de la visibilidad de un agente virtual en el desempeño y la confianza del usuario
en tareas de decisión basadas en reglas***

Profesor
Dr. Alexander Barquero

Investigador Principal:
Ney Fred Jiménez Campos

Fecha
5 de mayo 2026

I Ciclo, 2026

Título de la Investigación

Efecto de la visibilidad de un agente virtual en el desempeño y la confianza del usuario en tareas de decisión basadas en reglas

Situación Actual

En los últimos años los agentes virtuales se han instalado en casi todos los ámbitos de interacción digital: sistemas de atención al cliente, plataformas de aprendizaje, herramientas de apoyo a la toma de decisiones y entornos de simulación. Muchos de estos agentes combinan modelos de lenguaje de gran escala (LLM) con representaciones visuales animadas: avatares con expresiones faciales, lip-sync y gestos; esto bajo la premisa de que esto hace la experiencia más natural y efectiva para el usuario.

El problema es que esa premisa rara vez se ha verificado con rigor. La pregunta que la investigación en HCI todavía no tiene bien resuelta es si la representación visual del agente produce mejoras reales y objetivas en el desempeño del usuario, o si sus efectos son principalmente perceptuales. Dicho de otra forma: ¿verlo cambia cómo el usuario razona y decide, o solo cambia cómo se siente la interacción?

La distinción importa especialmente en tareas donde el usuario debe aplicar criterios explícitos y jerarquizados para llegar a una respuesta, esto es lo que llamamos tareas de decisión basadas en reglas. En esos contextos, un agente visible podría mejorar la precisión, o podría simplemente inflar la confianza sin un aumento proporcional en la exactitud. Ese segundo escenario tiene consecuencias serias en dominios donde equivocarse no es trivial: medicina, derecho, seguridad industrial.

Definición del Problema

La problemática que aborda esta investigación es relevante en varios niveles:

Académico: Los estudios sobre embodiment en agentes dan resultados contradictorios, y buena parte de esa contradicción viene de un problema de diseño: casi nadie controla que el contenido de la asistencia sea el mismo entre condiciones. Eso hace imposible saber si lo que cambia es el avatar o lo que dice.

Práctico: Desarrollar un agente animado cuesta tiempo y dinero. Si la diferencia entre un chatbot de texto y un avatar con lip-sync es solo estética, eso cambia bastante el cálculo de inversión para quienes toman esas decisiones.

Fiabilidad y seguridad: En tareas donde equivocarse tiene consecuencias, que el usuario se sienta más seguro de lo que realmente está es un problema concreto. No es un efecto menor ni teórico.

Diseño: Saber cuándo el avatar ayuda y cuándo solo distrae tiene implicaciones directas para quienes diseñan estos sistemas, especialmente en contextos donde la precisión no es opcional.

Población Afectada

El problema interesa principalmente a quienes diseñan y desarrollan sistemas con agentes virtuales. Más allá de ese grupo, afecta a cualquier usuario que trabaja con asistentes digitales en tareas que requieren razonamiento preciso. Y a nivel académico, toca a investigadores en HCI, psicología cognitiva y diseño conversacional, que comparten el problema, pero rara vez conversan entre sí.

Limitaciones de las Soluciones Actuales

La literatura existente tiene varias limitaciones o huecos, que justifican este estudio:

Falta de control del contenido: Muchos estudios comparan agentes con distintos niveles de embodiment sin asegurarse de que el contenido de la asistencia sea idéntico entre condiciones. Eso hace muy difícil atribuir las diferencias observadas exclusivamente al factor visual.

Sin medición de calibración: Pocos trabajos reportan simultáneamente precisión objetiva y confianza subjetiva. Sin ambas métricas juntas, no se puede calcular la brecha entre ellas ni detectar sobreconfianza. Si solo se mide una, no se puede saber realmente si el usuario está bien calibrado o simplemente seguro de algo incorrecto.

Equivalencia de dificultad no verificada: Asignar tareas distintas a grupos distintos sin validar que sean comparables en dificultad introduce ruido que los autores rara vez reconocen.

Experiencia tecnológica ignorada: Alguien que usa agentes virtuales todos los días va a responder distinto a alguien que los ve por primera vez. Esa variable casi nunca se controla.

Tareas conversacionales como default: La mayoría de los estudios usa tareas abiertas o de conversación libre. Los contextos de decisión con reglas explícitas, que son comunes en trabajo profesional real, están subrepresentados.

Estas limitaciones no son menores. Este proyecto las aborda directamente: el contenido de asistencia es idéntico entre condiciones B y C, se miden precisión y confianza por separado en cada pregunta, y se valida la dificultad de las tareas antes del experimento real.

Revisión de Literatura

Para la revisión de literatura, se decidió organizar los trabajos previos en cuatro bloques temáticos progresivos.

1. Modelos generales de confianza en sistemas automáticos.
2. Agentes conversacionales encarnados y sus efectos en el usuario.
3. Visibilidad del agente, expresiones faciales y calibración de confianza.
4. Herramientas de medición de experiencia de usuario.

Esa estructura no es arbitraria. El problema se ubica en la intersección de tres campos distintos (psicología de la confianza, HCI y diseño de agentes encarnados) que tienen tradiciones bibliográficas propias y que rara vez se citan entre sí.

Empezar desde los modelos generales de confianza en automatización permite establecer el marco conceptual antes de entrar a los agentes específicamente; sin ese piso, términos como calibración o sobreconfianza quedan flotando sin definición operacional.

El segundo bloque, sobre agentes conversacionales encarnados, sitúa el objeto de estudio dentro de su campo natural.

El tercero es donde convergen los dos anteriores: ahí está la evidencia empírica más directamente relacionada con las hipótesis del proyecto, sobre qué hace exactamente la visibilidad del agente a la confianza y al desempeño.

El cuarto bloque justifica la elección de instrumentos de medición, que de otro modo parecería arbitraria.

La progresión de lo general a lo específico es también el argumento: cada bloque construye sobre el anterior hasta llegar al hueco concreto que este estudio intenta llenar.

1. Modelos de Confianza en Sistemas Automáticos y Agentes IA

La confianza en sistemas automatizados lleva décadas estudiándose, pero los marcos conceptuales que todavía dominan la literatura vienen casi todos de los años noventa. Mayer, Davis y Schoorman (1995) definieron la confianza como la disposición de una parte a ser vulnerable a las acciones de otra, en función de expectativas positivas sobre sus intenciones [1]. Su marco tridimensional (habilidad, benevolencia e integridad) ha sido adoptado ampliamente en investigaciones sobre confianza en tecnología, incluyendo robots y agentes IA.

Lee y See (2004) trasladaron ese marco a la automatización, definiendo la confianza como "la actitud de que un agente ayudará a lograr los objetivos de un individuo en una situación caracterizada por incertidumbre y vulnerabilidad" [2]. Lo más útil de su revisión es el concepto de confianza apropiada: la idea de que el nivel de dependencia del usuario debería alinearse con la capacidad real del sistema. Cuando no es así (cuando el usuario confía más de lo que el sistema

justifica), los errores dejan de ser aleatorios y se vuelven sistemáticos. Ese desacople es el punto de partida de este estudio.

Glikson y Woolley (2020) revisaron la literatura empírica sobre confianza humana en IA y encontraron que las representaciones visuales antropomorfas aumentan consistentemente la confianza percibida [3]. Pero el efecto no es uniforme: varía según el contexto, la tarea y el perfil del usuario. Lo que la revisión deja sin resolver es si ese aumento de confianza se traduce en mejor desempeño real, o si simplemente ensancha la brecha entre lo que el usuario cree que hace y lo que efectivamente hace.

2. Agentes Conversacionales Encarnados: Fundamentos y Efectos en el Usuario

Los agentes conversacionales encarnados (ECAs) son sistemas que se presentan bajo una forma corporal (virtual o física) e interactúan con el usuario mediante lenguaje natural y señales no verbales sincronizadas. Cassell et al. (2000) argumentaron que esa presencia corporal activa mecanismos de interacción social análogos a los que usamos entre personas [4]. Fue el punto de arranque de un campo que lleva más de dos décadas produciendo evidencia sobre cómo el embodiment afecta la cognición y la colaboración humano-máquina.

Bickmore y Picard (2005) mostraron que los agentes virtuales pueden sostener relaciones de largo plazo con usuarios, generando niveles de confianza comparables a los interpersonales cuando el agente exhibe comportamientos relacionales básicos: saludos, pequeña charla, memoria de interacciones previas [5]. Lo que más pesa, según sus datos, no es la sofisticación técnica del agente sino la consistencia de su comportamiento a lo largo del tiempo.

Song et al. (2023) revisaron sistemáticamente 315 artículos sobre ECAs, chatbots y robots sociales, y encontraron que la investigación ha madurado en aplicaciones médicas, educativas e industriales, pero que los estudios comparativos que aíslan el efecto del embodiment de otras variables siguen siendo escasos [6]. El problema no es falta de evidencia sino falta de control: sabemos que los agentes encarnados generan más confianza, pero no cuánto de eso viene del avatar y cuánto de todo lo que trae consigo.

3. Efecto del Embodiment en Confianza, Desempeño y Calibración

Kulms y Kopp (2016) estudiaron cómo el embodiment y la competencia del agente afectan conjuntamente la confianza y la cooperación del usuario [7]. El hallazgo más interesante es que el embodiment ayuda al principio, pero ese efecto no dura: conforme avanza la interacción, lo que termina determinando la confianza es el desempeño real del agente. La presencia visual funciona como un crédito inicial que la competencia debe sostener.

En una extensión de ese trabajo, Kulms y Kopp (2018) usaron un paradigma de juego cooperativo tipo Tetris para mostrar que los usuarios aplican las mismas dimensiones de evaluación social (calor y competencia) a computadoras que a personas [8]. La implicación para el diseño de avatares es incómoda: la apariencia visual activa heurísticas sociales que pueden inflar la confianza independientemente de lo que el sistema haga bien o mal. Kulms y Kopp (2019) sumaron otro dato: la relación entre nivel de antropomorfismo y confianza no es lineal, y bajo ciertas condiciones de competencia y dependencia los efectos se invierten [9].

Shamekhi et al. (2018) compararon grupos de decisión facilitados por un agente con cara (avatar proyectado en robot) versus un agente solo-voz, con 20 grupos de participantes, y encontraron que el embodiment mejoró la percepción social del agente (rapport, confianza, inteligencia percibida) pero que su impacto en la calidad de las decisiones grupales dependió del tipo de asistencia prestada [10]. La visibilidad tiene efectos perceptuales robustos, pero los efectos funcionales son condicionales.

McMillan et al. (2023) ampliaron esa evidencia a un contexto de trabajo real con equipos de primera respuesta, comparando un robot humanoide, un altavoz inteligente y un sistema de diálogo [11]. El agente encarnado fue percibido como más confiable y mejoró el engagement respecto al altavoz, pero los autores advirtieron que los efectos dependen fuertemente del contexto y la tarea. Un hallazgo que funciona con equipos de primera respuesta no tiene por qué replicarse en tareas individuales de decisión basada en reglas.

Moradinezhad y Solovey (2021) trabajaron con tareas de opción múltiple asistidas por agentes cooperativos versus no cooperativos, y encontraron que el desempeño fue significativamente mayor con agentes cooperativos [12]. Lo que más importa de ese estudio es que la confianza dependió más de la historia de interacción que de las características visuales del agente. No basta con que se vea bien.

Luo et al. (2023) examinaron cuatro condiciones de expresión facial en avatares de realidad virtual (positiva, neutral, negativa y sin expresión) [13]. El resultado sorprendió: cualquier tipo de expresión, incluso negativa, fue más efectiva en modificar la confianza y las decisiones que la ausencia total de expresividad. La ausencia de animación facial es la peor opción, no una opción neutral.

Visconti et al. (2023) compararon rastreo facial con hardware especializado versus lip-sync basado en audio, con 28 participantes en entornos de realidad virtual social [14]. El rastreo facial superó al lip-sync en emociones de baja activación como tristeza o asco, pero la brecha se redujo para emociones de alta activación. Para tareas de decisión, el lip-sync mediante blendshapes sincronizadas con audio TTS es una alternativa accesible con presencia social suficiente.

Safi et al. (2024) estudiaron cómo el nivel de embodiment del agente (desde chatbot hasta ECA) y los comportamientos de Teoría de la Mente afectan la confianza percibida y la experiencia de usuario en agentes basados en LLM [15]. La forma antropomórfica influye positivamente en la confianza, pero combinar alto embodiment con comportamientos de ToM puede producir efectos no lineales y difíciles de predecir. En este experimento el LLM opera bajo restricciones explícitas de reglas, lo que debería atenuar ese efecto, aunque no necesariamente eliminarlo.

Zhang, Liao y Bellamy (2020) encontraron que mostrar los niveles de confianza del sistema mejora la precisión del usuario, pero que bajo ciertas condiciones también induce sobreconfianza: los usuarios calificaban su propia certeza más alto cuando el sistema presentaba alta confianza, incluso cuando ambos se equivocaban [16]. Un avatar visible podría operar por un mecanismo similar, inflando la confianza sin una mejora proporcional en la precisión.

Scharowski et al. (2023) revisaron 96 estudios empíricos sobre calibración de confianza en sistemas automatizados y documentaron que el tipo de tarea y el perfil del usuario moderan significativamente los efectos [17]. Los resultados de un dominio no se transfieren automáticamente a otro, y asumir que sí lo hacen es uno de los problemas recurrentes en esta literatura.

Wang et al. (2024) compararon sistemas sobreconfiados, subconfiados y bien calibrados, y encontraron que los usuarios expuestos a sistemas sobreconfiados adoptaron mayor dependencia y sobreestimaron su propia precisión, incluso cuando tomaban malas decisiones [18]. Si un avatar produce ese mismo efecto por la vía de la presencia visual, las consecuencias en contextos críticos pueden ser serias.

De Visser et al. (2020) propusieron que la confianza en equipos humano-robot no es estática, sino que evoluciona en función de las experiencias acumuladas de éxito y fracaso [19]. En este proyecto las tareas incluyen múltiples casos secuenciales, lo que podría activar esas mismas dinámicas durante la sesión. Si la confianza del participante sube o baja por razones ajenas a la condición asignada, eso contamina la comparación. Es una limitación que el análisis tendrá que reconocer explícitamente.

4. Instrumentos de Medición de Experiencia de Usuario y Confianza

Thüring y Mahlke (2007) propusieron el modelo CUE (Components of User Experience), que descompone la experiencia de usuario en tres componentes: percepciones instrumentales (utilidad, usabilidad), percepciones no instrumentales (estética, estatus) y reacciones emocionales [20]. Ese modelo es el fundamento teórico del cuestionario meCUE, y la razón por la que se eligió como instrumento principal de medición subjetiva.

Minge, Thüring, Wagner y Kuhr (2017) presentaron la primera versión validada del meCUE: 34 ítems organizados en cuatro módulos (percepciones del producto, emociones del usuario, consecuencias del uso y evaluación global) [21]. Los módulos de utilidad percibida y emociones son los más relevantes para este experimento, porque permiten medir por separado la percepción de utilidad y la confianza emocional en cada condición. Los estudios de validación reportaron buena consistencia interna y validez discriminante satisfactoria.

Minge y Thüring (2018) publicaron la versión 2.0, refinada para cumplir cinco criterios de medición estandarizada: comprensibilidad, eficiencia, inteligibilidad, calidad psicométrica y adaptabilidad [22]. Tiene versiones en español e inglés, lo que facilita su aplicación sin necesidad de traducción ni adaptación cultural adicional.

Síntesis y Brechas Identificadas

De la revisión anterior se pueden identificar cinco brechas concretas que este proyecto busca atender:

- El primero es el aislamiento del efecto visual. La mayoría de los estudios comparan agentes visibles contra ausencia total de agente, sin controlar que el contenido de la asistencia sea idéntico entre condiciones. Mientras eso no se controle, cualquier diferencia observada podría deberse al contenido tanto como a la presencia visual.
- El segundo es la medición de calibración. Pocos trabajos reportan simultáneamente precisión objetiva y confianza subjetiva. Sin ambas métricas juntas no se puede saber si el usuario está bien calibrado o simplemente seguro de algo incorrecto.

- El tercero es el tipo de tarea. La mayoría de los estudios usa tareas conversacionales o abiertas. Los entornos de decisión con reglas explícitas y jerarquizadas, que son comunes en trabajo profesional real, están subrepresentados.
- El cuarto es la validación de equivalencia de dificultad. Asignar tareas distintas a condiciones distintas sin verificar que sean comparables introduce sesgos que la mayoría de los autores no reconoce ni controla.
- El quinto es el contexto hispanohablante. La investigación sobre ECAs en español es escasa, y los efectos culturales e idiomáticos del agente vocal en TTS en español prácticamente no se han estudiado.

Preguntas de Investigación

Las preguntas de investigación se derivan de las brechas identificadas en la revisión y están formuladas para ser abordables dentro del alcance del curso, con un piloto acotado a expertos o pares y sin requerir autorización del CEC.

RQ1. Precisión

¿Existen diferencias estadísticamente significativas en la precisión de los usuarios (medida como porcentaje de respuestas correctas) entre las tres condiciones: sin agente (A), asistencia textual (B) y agente virtual visible (C), en tareas de decisión basadas en reglas?

Justificación: Esta pregunta aborda el efecto funcional más directo del agente. El embodiment mejora consistentemente la percepción social del agente [10], pero su efecto sobre el desempeño objetivo varía bastante entre estudios [7, 11]. Lo que la RQ1 busca resolver es si la visibilidad del agente produce alguna mejora en precisión más allá de lo que ya aporta el texto solo. Si B y C dan resultados similares, el avatar está haciendo algo, pero no es mejorar las decisiones.

RQ2. Confianza Subjetiva Reportada

¿Existen diferencias estadísticamente significativas en la confianza reportada por los usuarios (medida en escala Likert de 1 a 7 mediante sub-escalas del cuestionario meCUE 2.0) entre las tres condiciones de asistencia?

Justificación: La literatura muestra que el embodiment mejora la percepción de rapport, inteligencia y confianza en el agente [10, 15], y que incluso la asistencia textual sola puede elevar la confianza respecto a no tener ningún soporte [12]. Lo que no está claro es cuánto de ese efecto se debe a la visibilidad del agente y cuánto al contenido de la asistencia. RQ2 busca separar eso con un instrumento validado, mirando por separado la utilidad percibida y la confianza emocional.

RQ3. Calibración Confianza-Precisión

¿Cómo varía la calibración del usuario (definida como la relación entre la confianza subjetiva reportada y la precisión real obtenida) según la condición del agente? Específicamente, ¿en qué condición se observa mayor brecha de sobreconfianza?

Justificación: Si el agente visible eleva la confianza sin una mejora proporcional en precisión, eso confirmaría que el avatar produce un efecto perceptual que no se traduce en mejores decisiones [16, 17, 18]. Ese es el escenario más problemático en dominios donde equivocarse tiene consecuencias: el usuario se siente más seguro, pero no decide mejor. RQ1 y RQ2 caracterizan los efectos por separado; RQ3 los cruza para ver si la brecha existe y en qué condición es mayor.

Objetivos del Agente

Rol del Agente

El agente cumple el rol de asistente de reglas en tareas de decisión estructurada. Su función es estrictamente aclaratoria: no da la respuesta correcta, sino que ayuda al usuario a entender e interpretar las reglas que gobiernan la tarea. Si el agente resolviera las tareas directamente, la condición C sería indistinguible de una simple consulta de respuestas y no habría varianza en precisión que analizar.

Operacionalmente, el agente puede:

1. Explicar el significado de una regla cuando el usuario lo solicita.
2. Aclarar cómo se aplican múltiples reglas que se activan simultáneamente, indicando el principio de prioridad.
3. Confirmar que la respuesta fue registrada y avanzar al siguiente caso.
4. Redirigir cordialmente cuando el usuario intenta obtener la respuesta directa, devolviendo el control de la decisión al participante.

El agente no tiene memoria persistente entre sesiones, no hace seguimiento del historial de errores del usuario y no adapta su comunicación al perfil del participante. Todo eso se sacrificó para mantener el control experimental: si el agente se personalizara, las diferencias entre condiciones podrían deberse a esa adaptación y no a la visibilidad del avatar.

Comportamiento y Personalidad

El agente mantiene un tono neutro, profesional y cordial. Las respuestas son concisas (dos a cuatro oraciones como máximo), sin jerga técnica, formuladas en segunda persona singular informal ("vos", acorde al español costarricense). El agente no muestra emociones exageradas ni se disculpa innecesariamente.

En la condición C con el agente visible, el avatar sincroniza sus movimientos labiales con el audio TTS mediante blendshapes, y muestra expresiones faciales neutras durante la escucha y levemente positivas al confirmar respuestas. Las expresiones se mantienen en un rango moderado para evitar el efecto del uncanny valley, que la literatura documenta como factor de pérdida de confianza en avatares con animaciones artificialmente exageradas.

Contexto de Uso

El agente opera en un entorno virtual, accesible desde cualquier computador con acceso a internet. La interacción es exclusivamente textual en la condición B y textual más voz sintetizada y animación del avatar en la condición C. No se requiere micrófono ni hardware adicional del lado del usuario.

La sesión experimental dura entre 40 y 60 minutos e incluye:

1. Lectura de instrucciones.
2. Una tarea de práctica sin registro de datos, para asegurarse de que el usuario entendió las reglas.
3. Entre seis y ocho casos de decisión con registro de respuesta, tiempo y confianza auto reportada.
4. El cuestionario meCUE 2.0 al finalizar.

El participante trabaja individualmente; el evaluador no está presente durante el llenado, para reducir el sesgo de deseabilidad social.

Usuario Objetivo

Los participantes objetivo son personas de 18 años o más, con acceso habitual a computadoras y familiaridad básica con interfaces digitales. No se requiere experiencia previa con agentes virtuales. Se excluyen participantes con daltonismo severo o dificultades de lectura que puedan sesgar las tareas textuales.

Se estima un tamaño de muestra de 9 a 15 participantes con diseño within-subjects, donde cada participante pasa por las tres condiciones. Para un piloto exploratorio ese tamaño es suficiente; el objetivo no es inferencia poblacional sino detectar patrones y ajustar el diseño.

Objetivos Funcionales del Agente

1. Responder consultas sobre reglas con latencia máxima de 3 segundos.
2. Mantener coherencia con la base de reglas en el 100% de las respuestas, sin información fuera del dominio. Esto se controla mediante un system prompt restrictivo.
3. Registrar automáticamente cada respuesta junto con el timestamp y el nivel de confianza reportado (1-7).
4. Reproducir audio TTS en español con lip-sync sincronizado en la condición C, con latencia de inicio menor a 2 segundos.
5. Mantener el contenido textual idéntico entre condiciones B y C; la única diferencia es la presencia o ausencia del avatar y el audio.

Arquitectura Técnica Preliminar

La arquitectura propuesta integra cuatro subsistemas principales:

1. La interfaz de usuario (frontend).
2. El módulo de lenguaje natural (LLM).
3. El módulo de síntesis de voz y animación (TTS + avatar).
4. El subsistema de registro de datos experimentales. La Figura 1 ilustra el flujo de información entre estos componentes.




Figura 1. Arquitectura técnica preliminar del sistema experimental.

1. Dispositivo y Entorno de Despliegue

El sistema se ejecuta como una aplicación standalone dentro de un entorno virtual controlado por el investigador, al que los participantes acceden de forma remota desde sus propios equipos. Cada participante se conecta a la misma máquina virtual, lo que garantiza que todos corren exactamente la misma versión del software, con la misma resolución, el mismo sistema operativo y las mismas condiciones de renderizado.

Eso elimina la variabilidad entre dispositivos: no importa si el participante tiene Windows o Mac, un equipo viejo o nuevo. Los datos se registran directamente en el servidor del investigador, sin depender del dispositivo personal del participante ni de que configure nada. Y es más barato en

tiempo de desarrollo que montar una versión web completa, dado que la aplicación ya existe como build standalone. Lo que sí hay que verificar antes del experimento real es que la máquina virtual tenga capacidad gráfica suficiente para renderizar el avatar 3D con blendshapes en tiempo real. Eso se confirma en el piloto.

2. Interfaz de Usuario (Frontend)

La interfaz tiene las siguientes áreas diferenciadas:

- a) Pantalla de inicio, donde el usuario lee y acepta el consentimiento informado. Si no acepta, no puede continuar.
- b) Panel de selección de escenario, donde el usuario elige con cuál de los tres bloques va a comenzar, siguiendo el orden que se le indicó.
- c) Panel de preguntas, donde se presenta el caso de decisión con sus opciones de respuesta.
- d) Ventana emergente de confianza, que aparece después de cada respuesta y antes de avanzar a la siguiente pregunta. El usuario debe indicar su nivel de confianza en escala de 1 a 7 antes de poder continuar. Esto captura el dato en el momento exacto, no de forma retrospectiva.
- e) Panel del agente, que muestra el avatar en la condición C o el cuadro de chat en la condición B.

En la condición A, el panel del agente está deshabilitado y no hay acceso a chat. En la condición B, el panel muestra únicamente texto, sin animación ni voz. En la condición C, el panel contiene el canvas Unity con el avatar 3D, sincronización labial y expresiones faciales.

3. Módulo de Lenguaje Natural (LLM)

El procesamiento del lenguaje natural se delega a un modelo de lenguaje accedido vía API. La primera opción es GPT-4o mini (OpenAI) y las alternativas son Claude Haiku (Anthropic) o ElevenLabs, con latencias de respuesta menores a 2 segundos para respuestas cortas. La elección dependerá de la disponibilidad de créditos y los resultados del piloto.

El system prompt incorpora el conjunto completo de reglas del experimento, instrucciones de comportamiento y restricciones de salida. Eso reduce el riesgo de que el modelo proporcione respuestas fuera del dominio o revele la respuesta directamente, aunque no lo elimina por completo. El backend maneja las llamadas a la API añadiendo el historial de la sesión en cada request para mantener coherencia conversacional.

4. Módulo de Síntesis de Voz y Animación del Avatar

Una vez que el LLM genera la respuesta, el backend la envía a un servicio TTS. Se evalúan dos opciones: Claude (mayor naturalidad, costo por carácter) y Google Cloud TTS (menor costo, calidad suficiente para voz neutral). Ambos soportan español latinoamericano. El audio resultante se envía al cliente junto con los datos de visemas (unidades visuales del fonema) que controlan las blendshapes del avatar.

El avatar es un modelo 3D humanoide de Turbosquid, con rigging completo y blendshapes preconfiguradas para lip-sync, renderizado en Unity LTS. Las expresiones faciales (neutral durante la escucha, ligera sonrisa al confirmar) se activan mediante animaciones de estado controladas desde el backend según el tipo de respuesta del agente.

5. Subsistema de Registro de Datos

Cada interacción del usuario genera un registro con los siguientes campos: identificador de participante (anónimo), condición asignada (A/B/C), número de pregunta, respuesta seleccionada, respuesta correcta, indicador de acierto (booleano), timestamp de inicio y fin del caso, tiempo de respuesta en segundos, y nivel de confianza reportado (1–7). Estos registros se almacenan en el backend y se exportan como CSV para el análisis estadístico.

El cuestionario meCUE 2.0 se administra al finalizar la sesión vía Google Forms o Qualtrics, con un enlace generado automáticamente desde la interfaz al completar el último caso. Se usan los módulos de utilidad percibida, intención de uso y evaluación global del meCUE, complementados con una escala Likert de 3 ítems sobre confianza en la decisión tomada. El evaluador no está presente durante el llenado del cuestionario para reducir el sesgo de deseabilidad social.

6. Justificación de las Decisiones Tecnológicas

La combinación Unity + TTS + LLM vía API se eligió por razones prácticas y académicas. Unity tiene soporte maduro para el tipo de avatar que requiere el experimento y una curva de aprendizaje manejable dentro del tiempo disponible. Todas las herramientas tienen documentación pública y versiones gratuitas o de bajo costo, lo que hace el proyecto reproducible. Y el uso de avatares 3D con lip-sync mediante blendshapes es el estado del arte en ECAs de bajo costo según literatura reciente [13, 14, 15].

Se usa una API de LLM externa en lugar de un modelo local porque la calidad de respuesta en español de los modelos locales disponibles no es suficiente para el experimento. Las API keys no se suben al repositorio de GitHub; se manejan mediante variables de entorno.

Resumen del Stack Tecnológico

Tabla 1. Componentes del stack tecnológico propuesto.

Componente	Decisión / Herramienta	Justificación
Dispositivo	Una máquina virtual controlada por el investigador a la que los participantes acceden remotamente.	Acceso universal sin instalación local requerida.
Frontend	Aplicación standalone de Unity que corre dentro del entorno virtual.	Modularidad por condición; Unity para el avatar 3D.
Avatar / Embodiment	Modelo 3D Turbosquid; rigging completo; blendshapes para lip-sync	Calidad visual suficiente; costo accesible; compatible con Unity
Motor de rendering	Unity 2022.3 LTS	Soporte robusto para avatares 3D; amplia documentación
LLM	GPT-4o mini (OpenAI API) alternativa: Claude Haiku (Anthropic)	Calidad de respuesta en español; restricción via system prompt
TTS	ElevenLabs o Google Cloud TTS español latinoamericano	Naturalidad vocal; compatibilidad con datos de visemas
Lip-sync	Blendshapes activadas por visemas del audio TTS en tiempo real	Técnica validada en literatura; sin hardware adicional [14]
Backend	Python (FastAPI) con CSV / JSON	Middleware LLM + TTS; registro de datos experimentales
Cuestionario	meCUE 2.0 vía Google Forms o Qualtrics	Instrumento validado [21, 22]; fácil distribución y exportación
Control de versiones	GitHub (sin API keys en el repositorio)	Requerimiento del entregable; buenas prácticas de seguridad

Nota: Es posible que esta arquitectura no sea la final. Las decisiones sobre TTS y LLM se tomarán en función de disponibilidad de créditos y resultados del piloto. La arquitectura será iterada en los entregables posteriores del curso.

Referencias bibliográficas

- [1] Mayer, R. C., Davis, J. H., & Schoorman, F. D. (1995). An integrative model of organizational trust. *Academy of Management Review*, 20(3), 709-734.
<https://doi.org/10.5465/amr.1995.9508080335>
- [2] Lee, J. D., & See, K. A. (2004). Trust in automation: Designing for appropriate reliance. *Human Factors: The Journal of the Human Factors and Ergonomics Society*, 46(1), 50–80.
https://www.researchgate.net/publication/8555432_Trust_in_Automation_Designing_for_Appropriate_Reliance
- [3] Glikson, E., & Woolley, A. W. (2020). Human trust in artificial intelligence: Review of empirical research. *Academy of Management Annals*, 14(2), 627–660.
https://kilthub.cmu.edu/articles/journal_contribution/Human_Trust_in_Artificial_Intelligence_Review/19500545
- [4] Cassell, J., Sullivan, J., Prevost, S., & Churchill, E. (Eds.). (2000). *Embodied conversational agents*. MIT Press.
- [5] Bickmore, T. W., & Picard, R. W. (2005). Establishing and maintaining long-term human-computer relationships. *ACM Transactions on Computer-Human Interaction*, 12(2), 293-327.
<https://doi.org/10.1145/1067860.1067867>
- [6] Song, Y., Luximon, A., & Luximon, Y. (2023). Psychological insights into the research and practice of embodied conversational agents, chatbots and social assistive robots: A systematic meta-review. *Behaviour & Information Technology*.
<https://doi.org/10.1080/0144929X.2023.2286528>
- [7] Kulms, P., & Kopp, S. (2016). The effect of embodiment and competence on trust and cooperation in human-agent interaction. In *Intelligent Virtual Agents, IVA 2016. Lecture Notes in Computer Science*, vol 10011 (pp. 75-84). Springer. https://doi.org/10.1007/978-3-319-47665-0_7
- [8] Kulms, P., & Kopp, S. (2018). A social cognition perspective on human-computer trust: The effect of perceived warmth and competence on trust in decision-making with computers. *Frontiers in Digital Humanities*, 5, 14. <https://doi.org/10.3389/fdigh.2018.00014>
- [9] Kulms, P., & Kopp, S. (2019). More human-likeness, more trust? The effect of anthropomorphism on self-reported and behavioral trust in continued and interdependent human-agent cooperation. In *Proceedings of Mensch und Computer 2019* (pp. 209-214). ACM. <https://doi.org/10.1145/3340764.3340786>
- [10] Shamekhi, A., Liao, Q. V., Wang, D., Bellamy, R. K. E., & Erickson, T. (2018). Face value? Exploring the effects of embodiment for a group facilitation agent. In *Proceedings of the 2018 CHI Conference on Human Factors in Computing Systems* (Paper 391). ACM. <https://doi.org/10.1145/3173574.3173965>
- [11] McMillan, D., Jokinen, K., & Lemon, O. (2023). Seeing eye to eye: Trustworthy embodiment for task-based conversational agents. *Frontiers in Robotics and AI*, 10, 1234767.
<https://doi.org/10.3389/frobt.2023.1234767>

- [12] Moradinezhad, R., & Solovey, E. T. (2021). Investigating trust in interaction with inconsistent embodied virtual agents. In *Proceedings of the 26th International Conference on Intelligent User Interfaces* (pp. 327–337). ACM. <https://doi.org/10.1145/3397481.3450675>
- [13] Luo, L., Weng, D., Ding, N., Hao, J., & Tu, Z. (2023). The effect of avatar facial expressions on trust building in social virtual reality. *The Visual Computer*, 39(11), 5869–5882. <https://doi.org/10.1007/s00371-022-02700-1>
- [14] Visconti, A., Orso, V., Gamberini, L., Gini, G., Covaciu, A. L., & Zancanaro, M. (2023). Comparing technologies for conveying emotions through realistic avatars in virtual reality-based metaverse experiences. *Computer Animation and Virtual Worlds*, 34(3-4), e2188. <https://doi.org/10.1002/cav.2188>
- [15] Safi, M., Hößle, J., Jäger, M., Kiefer, P., & Raubal, M. (2024). "Am I understood?": How the interplay between embodiment and Theory of Mind behavior affects LLM-based conversational agents on perceived trust, anthropomorphism, presence, usability, and user experience. *ACM Transactions on Interactive Intelligent Systems*. <https://doi.org/10.1145/3774779>
- [16] Zhang, Y., Liao, Q. V., & Bellamy, R. K. E. (2020). Effect of confidence and explanation on accuracy and trust calibration in AI-assisted decision making. In *Proceedings of the 2020 ACM Conference on Fairness, Accountability, and Transparency* (pp. 295–305). ACM. <https://doi.org/10.1145/3351095.3372852>
- [17] Scharowski, N., Perrig, S. A. C., von Ah, U., Bruhlmann, F., Wintersberger, P., Hauptmann, B., & Antona, M. (2023). Measuring and understanding trust calibrations for automated systems: A survey of the state-of-the-art and future directions. In *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems* (Article 481). ACM. <https://doi.org/10.1145/3544548.3581197>
- [18] (preprint) Li, J., Yang, Y., Zhang, R., Liao, Q. V., Song, T., Xu, Z., & Lee, Y. (2024). Understanding the effects of miscalibrated AI confidence on user trust, reliance, and decision efficacy. *arXiv preprint arXiv:2402.07632*. <https://arxiv.org/abs/2402.07632>
- [19] de Visser, E. J., Peeters, M. M. M., Jung, M. F., Kohn, S., Shaw, T. H., Pak, R., & Neerincx, M. A. (2020). Towards a theory of longitudinal trust calibration in human–robot teams. *International Journal of Social Robotics*, 12(2), 459–478. <https://doi.org/10.1007/s12369-019-00596-x>
- [20] Thüring, M., & Mahlke, S. (2007). Usability, aesthetics and emotions in human–technology interaction. *International Journal of Psychology*, 42(4), 253–264. https://www.researchgate.net/publication/247509276_Usability_aesthetics_and_emotions_in_human-technology_interaction
- [21] Minge, M., Thüring, M., Wagner, I., & Kuhr, C. V. (2017). The meCUE questionnaire: A modular tool for measuring user experience. In *Advances in Ergonomics Modeling, Usability & Special Populations. Advances in Intelligent Systems and Computing*, vol 486 (pp. 115–128). Springer. https://doi.org/10.1007/978-3-319-41685-4_11
- [22] Minge, M., & Thüring, M. (2018). The meCUE questionnaire (2.0): Meeting five basic requirements for lean and standardized UX assessment. In *Design, User Experience, and*

Usability: Theory and Practice. DUXU 2018. Lecture Notes in Computer Science, vol 10918 (pp. 463-475). Springer. https://doi.org/10.1007/978-3-319-91797-9_33

Nota de uso de herramientas de IA

Durante la elaboración de este documento se utilizaron herramientas de inteligencia artificial generativa, específicamente ChatGPT (OpenAI) y Claude (Anthropic), como apoyo en tareas de organización de ideas, revisión de redacción y reformulación de párrafos. Todo el contenido, los argumentos, las decisiones de diseño y la selección de fuentes son de autoría propia. Las herramientas se usaron como asistentes de escritura, no como generadores de contenido académico.