

Entregable 2: Diseño Metodológico y Guion Experimental

PF-3311 · Agentes Virtuales Inteligentes

Investigador Principal: Ney Fred Jiménez Campos (B03230)
Universidad de Costa Rica, Programa de Posgrado en Computación e Informática
Profesor: Dr. Alexander Barquero
Fecha: Mayo 2026

Apartado A: Definición de Condiciones Experimentales

Nota sobre nomenclatura. El enunciado rotula la condición experimental como "Condición A" y el control como "Condición B" (ejemplificando este último como una interfaz conversacional en texto plano). Como este estudio opera con tres condiciones y no dos, la correspondencia es la siguiente: la condición experimental del enunciado equivale a la **Condición C** (Agente Virtual Visible); el control del enunciado, la interfaz en texto, equivale a la **Condición B** (Asistencia Textual); y se incorpora además una **Condición A** (Baseline Puro, sin agente) que el enunciado no contempla, añadida para poder aislar el efecto del *embodiment* del efecto del contenido de la asistencia, según se justifica al final del apartado.

Condición A: Baseline Puro (Sin Agente)

Cada escenario presentado en la aplicación Unity incluye sus propias reglas de decisión, desplegadas junto al enunciado del caso. El participante lee las reglas y el caso en la misma pantalla, sin acceso a ningún sistema de asistencia: ni chat, ni voz, ni avatar. El panel del agente está deshabilitado y no es visible. Los escenarios no se repiten entre bloques; cada pregunta es única. Esta condición muestra qué puede resolver el participante por sí solo. De ahí sale la línea base del análisis.

Condición B: Asistencia Textual (Chatbot sin Avatar)

El participante tiene acceso a un panel de chat de texto durante toda la sesión. Puede escribir preguntas sobre las reglas del escenario que está leyendo, y el sistema responde mediante texto en pantalla, generado por un LLM (Google Gemini API) bajo un *system prompt* que restringe las respuestas a las reglas del caso en curso. El agente puede explicar el significado de una regla, aclarar cómo aplicar reglas en conflicto e indicar el principio de prioridad correspondiente, pero en ningún caso revela la respuesta correcta. No hay representación visual del agente, no hay voz sintetizada ni ningún elemento animado. La interfaz es igual a un chat de texto convencional. El agente existe, pero no tiene cara ni voz.

Condición C: Agente Virtual Visible (Condición Experimental)

El participante interactúa con el mismo sistema de asistencia que en la Condición B (mismo LLM, mismo *system prompt*, mismas reglas por escenario), con la diferencia de que el agente adopta una representación visual completa: un avatar humanoide 3D renderizado en tiempo real dentro de un *canvas* de Unity, con sincronización labial (*lip-sync*) mediante *blendshapes* activadas por los visemas del audio TTS, y expresiones faciales neutras durante la escucha y levemente positivas al confirmar que la respuesta fue registrada. La voz es sintetizada en español latinoamericano (OpenAI TTS). El tono verbal es el mismo que en la Condición B: neutro, profesional, cordial, en segunda persona singular informal ("vos"). Las animaciones faciales se mantienen dentro de un rango moderado para evitar el efecto del *uncanny valley*.

Justificación de la Comparación

El enunciado pide un diseño de dos condiciones, experimental y control. Trabajo con tres porque con dos no se puede separar el efecto del avatar del efecto de la asistencia textual: si comparara directamente un agente visible (C) contra ninguna asistencia (A), cualquier diferencia podría deberse al contenido de la ayuda, a la presencia del avatar, o a ambos a la vez. La Condición B es la pieza que vuelve interpretable la comparación. Esta decisión responde al vacío metodológico identificado en la revisión de literatura: Song et al. (2023) señalaron que los estudios que aíslan el efecto del *embodiment* de las demás variables siguen siendo escasos, y que la mayoría compara agentes visibles contra ausencia total de agente sin controlar que el contenido de la asistencia sea idéntico entre condiciones. Sin esa condición intermedia, ninguna diferencia observada puede atribuirse causalmente al factor visual [6].

B vs. C aísla el efecto de la visibilidad del agente. Como el contenido de la asistencia es idéntico entre ambas (mismo modelo de lenguaje, mismo *system prompt*, mismas reglas por escenario), cualquier diferencia en precisión, confianza o calibración entre B y C es atribuible solo a la presencia del avatar y el audio, no a lo que el agente dice. Esta es la comparación central para las tres preguntas de investigación.

A vs. B aísla el efecto de la asistencia textual sobre el desempeño base. Si B supera a A en precisión, se confirma que la

asistencia por reglas tiene valor funcional independiente de cómo se presente.

A vs. C mide el efecto combinado: asistencia más representación visual. Sin la comparación con B, esta diferencia sería ininterpretable.

El diseño *within-subjects* (cada participante pasa por las tres condiciones en orden contrabalanceado) maximiza la potencia estadística con la muestra reducida disponible (9 a 15 personas) y controla las diferencias individuales en la capacidad de razonamiento basado en reglas, específicas de cada escenario.

Apartado B: Matriz de Consistencia Metodológica

Pregunta de Investigación (RQ)	Variable / Constructo	Instrumento Validado	Tarea Asociada en el Guión
RQ1 (Precisión). ¿Existen diferencias estadísticamente significativas en la precisión de los usuarios (porcentaje de respuestas correctas) entre las condiciones A (sin agente), B (texto) y C (agente visible)?	Precisión objetiva por ítem: variable binaria (correcto / incorrecto) y agregada como porcentaje por condición.	Registro automático del sistema: cada respuesta seleccionada se compara contra la respuesta correcta almacenada en el backend y se guarda en el CSV experimental junto con <i>timestamp</i> e ID del participante. No requiere cuestionario externo.	El participante lee el escenario en pantalla, que incluye las reglas propias del caso junto al enunciado. Decide libremente si consultar o no al agente (según la condición) y selecciona una de las cuatro opciones disponibles. Ningún escenario se repite entre bloques. Al confirmar la selección, el sistema registra el acierto antes de mostrar la escala de confianza. El participante no recibe retroalimentación sobre si acertó o erró; la sesión avanza directamente a la escala de confianza y luego al siguiente caso. El flujo es idéntico en las tres condiciones para que el conocimiento del acierto no afecte las respuestas siguientes.
RQ2 (Confianza Subjetiva). ¿Existen diferencias estadísticamente significativas en la confianza reportada por los usuarios entre las tres condiciones?	Percepción del sistema (utilidad percibida, emociones, intención de uso, evaluación global) y confianza específica en las decisiones tomadas, como constructos subjetivos de la experiencia de usuario.	meCUE 2.0 (Minge & Thüring, 2018): módulos de percepciones instrumentales, emociones, intención de uso y evaluación global, con versión en español disponible [22]. meCUE mide experiencia de usuario, no confianza en sentido estricto, por lo que sus módulos operan como medida del juicio global del sistema. La confianza específica en las decisiones se captura con tres ítems Likert adicionales (1-7) y con la escala de confianza inline ítem a ítem; estos ítems complementarios no están validados de forma independiente, lo que se reconoce como limitación de constructo. Esto precisa la formulación del Entregable 1, donde la confianza de RQ2 se asociaba al meCUE: aquí el meCUE se conserva para la experiencia de usuario y la medición de la confianza específica se asigna a los ítems Likert dedicados.	Al completar el último caso de cada bloque, el participante recibe el enlace al cuestionario meCUE 2.0 directamente desde la interfaz, antes de que el investigador regrese a la sala. El cuestionario se administra tres veces en total (una por condición) para capturar la percepción de cada versión del sistema por separado, no como evaluación global al final. El participante lo llena solo, sin el investigador presente, para que las respuestas reflejen su percepción real.
RQ3 (Calibración Confianza-Precisión). ¿Cómo varía la calibración del usuario (relación entre confianza subjetiva y precisión real) según la condición? ¿En qué condición se observa mayor brecha de sobreconfianza?	Calibración por ítem, definida sobre escalas comparables: la confianza (1-7) se normaliza al rango [0, 1] mediante $(\text{confianza} - 1) / 6$ y se le resta el acierto del mismo ítem (0 = incorrecto, 1 = correcto). El índice resultante vive en [-1,	Escala Likert de confianza inline (1-7) capturada ítem a ítem mediante ventana emergente obligatoria post-respuesta, antes de avanzar al siguiente caso. Se cruza con el indicador de corrección del mismo ítem en el CSV. La calibración no puede calcularse solo con el meCUE (que es global); requiere la medición	Apenas el participante confirma su respuesta, antes de saber si acertó, aparece una ventana emergente: "¿Qué tan seguro/a estás de tu respuesta?". El participante indica su nivel de confianza (1 = nada seguro/a, 7 = completamente seguro/a) y no puede avanzar sin responder. El mecanismo captura el dato en el momento exacto de la decisión, no de forma retrospectiva, lo que es crítico para calcular la calibración por ítem: la diferencia entre la confianza

	+1]: un valor positivo indica sobreconfianza (alta confianza, respuesta incorrecta) y uno negativo, subconfianza.	por ítem.	normalizada y el booleano de acierto del mismo ítem es la unidad de análisis de RQ3.
--	---	-----------	--

Análisis estadístico previsto

El análisis compara tres mediciones repetidas dentro del mismo participante (diseño *within-subjects*). Para detectar diferencias globales entre condiciones se usa la prueba de Friedman (χ^2), y como post-hoc, la prueba de Wilcoxon con corrección de Bonferroni sobre las tres comparaciones por par (A vs. B, B vs. C, A vs. C). Se opta por estadística no paramétrica dado el tamaño de muestra reducido (9 a 15 participantes). Esto aplica a RQ1 (precisión media por condición) y a RQ2 (puntajes meCUE y confianza por condición). Para RQ3 se calcula, por participante y condición, el promedio del índice de calibración por ítem, es decir $(\text{confianza} - 1)/6 - \text{acierto}$, y se compara entre condiciones con el mismo procedimiento Friedman + Wilcoxon; las curvas de calibración ítem a ítem complementan el índice global.

Sobre la potencia y el balance del diseño, conviene ser claro: con una n de entre 9 y 15 las pruebas rara vez alcanzarán significancia, así que el estudio es exploratorio y prioriza los tamaños de efecto y los patrones descriptivos por encima del umbral $p < .05$. El contrabalanceo de orden, por su parte, queda completo y balanceado solo con un múltiplo de 6 (idealmente 12 participantes); con 9 es parcial.

Apartado C. El protocolo oficial del investigador se entrega como archivo HTML adjunto (`Protocolo_Investigador_PF3311_NeyFredJimenez.html`), que cubre la identificación formal del estudio, el consentimiento informado y la aceptación obligatoria, la carga de condición por asignación aleatoria, las instrucciones neutrales anti-*priming*, los cuestionarios post-interacción y el plan de anonimización y resguardo de los *logs*.

Apartado D: Justificación Teórica en HCI

Las decisiones de diseño del agente en la Condición C no son arbitrarias. Cada una responde a un problema documentado en la literatura de HCI y tiene un respaldo empírico que puedo señalar con precisión.

Soporte no verbal del *embodiment* del avatar (Justine Cassell)

Cassell et al. (2000) argumentaron que los agentes conversacionales encarnados activan mecanismos de interacción social análogos a los que usamos entre humanos. La premisa central es que la presencia de un cuerpo, aunque sea virtual, no es decorativa: es el canal que hace posibles las señales no verbales que estructuran la conversación y modulan la interpretación del mensaje [4]. Cuando un hablante sincroniza sus movimientos labiales con el discurso, asiente al procesar una pregunta o muestra una expresión coherente con lo que acaba de decir, el interlocutor humano usa esas señales para calibrar la atención, la intención y la confiabilidad del agente.

En este diseño ese principio se aplica de forma acotada y consciente. La sincronización labial mediante *blendshapes* activadas por los visemas del audio TTS es la traducción técnica más directa de lo que Cassell llama *continuers* no verbales: señales de que el agente produce un discurso coherente y sincronizado con su representación corporal. Las expresiones neutras durante la escucha y levemente positivas al confirmar respuestas replican lo que, en la interacción humana, señala comprensión activa y respuesta apropiada al contexto. Mantuve las expresiones en un rango moderado porque la literatura posterior a Cassell, en particular Luo et al. (2023), muestra que cualquier expresividad supera a la ausencia de animación, pero que la exageración dispara el *uncanny valley* y erosiona la confianza [13]. El objetivo no es un agente muy expresivo. Es uno suficientemente expresivo.

Diseño del soporte relacional y lazos afectivos (Timothy Bickmore)

Bickmore y Picard (2005) demostraron que los agentes virtuales pueden construir confianza relacional cuando exhiben comportamientos consistentes a lo largo del tiempo: saludos, reconocimiento del historial de interacción y pequeña charla apropiada al contexto. Lo más relevante para este diseño es que la consistencia del comportamiento pesa más que la sofisticación técnica del agente [5]. Un avatar simple que se comporta de manera predecible y cordial genera más confianza que uno técnicamente elaborado pero errático.

Aquí esa lección se aplicó con un límite claro: sacrifiqué la memoria persistente para no contaminar el control experimental. Si el agente adaptara su comportamiento al historial de errores del participante, las diferencias entre condiciones podrían atribuirse a esa adaptación y no a la visibilidad del avatar. Lo que sí se preserva del marco de Bickmore es la consistencia: el tono neutro, profesional y cordial en segunda persona singular informal ("vos", acorde al español costarricense) se mantiene igual en todas las interacciones de la Condición C. El agente no se disculpa de más, no muestra emociones exageradas y redirige con cordialidad cuando el participante intenta sacarle la respuesta directa. Esa consistencia es la forma en que el principio relacional de Bickmore cabe dentro de las restricciones del diseño.

Efecto Proteus y variaciones de comportamiento inducidas por el avatar (Nick Yee y Jeremy Bailenson)

Yee y Bailenson (2007) describieron el Efecto Proteus como el fenómeno por el cual los usuarios modifican su propio comportamiento en función de la apariencia del avatar con el que interactúan o que los representa. En su formulación original, el efecto opera sobre el usuario que encarna el avatar [23]. Aplicado al diseño de un ECA, donde el usuario interactúa con el avatar pero no lo encarna, el mecanismo relevante es análogo: la apariencia y el comportamiento del agente visible activan heurísticas sociales que pueden cambiar cómo razona el usuario, cuánta confianza atribuye al sistema y cuánto peso le da a las sugerencias. No encarna el avatar, pero igual reacciona ante él.

En este experimento el Efecto Proteus tiene una implicación concreta que la RQ3 busca medir de frente: si el avatar con expresiones levemente positivas al confirmar respuestas induce más confianza en el participante con independencia de si acertó, eso es exactamente el mecanismo que Zhang et al. (2020) y Li et al. (2024) documentaron en sistemas con alta confianza declarada. El participante se siente más seguro no porque haya decidido mejor, sino porque el agente visible disparó una heurística social de validación [16, 18]. Ese resultado (más confianza sin más precisión, es decir, sobreconfianza inducida por el *embodiment*) es el peor caso desde la perspectiva de Yee y Bailenson, y es justo lo que este diseño está armado para detectar si ocurre.

Síntesis: cómo encajan los tres marcos

No veo estos tres marcos como pilares separados, sino como una sola línea de razonamiento que sostiene el diseño de la Condición C. El punto de partida es Cassell: sin un cuerpo, aunque sea virtual, no hay señales no verbales, y sin esas señales agregar *lip-sync* o expresiones faciales sería pura decoración. Bickmore me sirve para lo siguiente, que es más práctico: lo que construye confianza no es qué tan elaborado se ve el avatar, sino qué tan predecible es su comportamiento; por eso preferí sacrificar la memoria persistente antes que arriesgar la consistencia del tono entre interacciones. Y Yee y Bailenson son la advertencia que no quería perder de vista: ese mismo mecanismo social que vuelve útil al avatar puede dispararse en falso e inflar la confianza del participante aunque sus decisiones no mejoren.

Lo interesante es que, juntos, los tres marcos no predicen un único resultado sino varios, y el experimento está armado para distinguirlos. Si el avatar sube a la vez la precisión y la confianza, gana la lectura optimista de Cassell y Bickmore. Si sube la confianza pero la precisión se queda donde estaba, aparece el riesgo que advirtieron Yee y Bailenson: la sobreconfianza inducida por el *embodiment*, el peor escenario para cualquier dominio donde equivocarse cuesta caro. Y si no se mueve ninguna de las dos variables, el resultado nulo igual aporta: ayuda a delimitar cuándo el *embodiment* vale la pena. La RQ3 es la que cierra el argumento, porque sin medir precisión y confianza juntas, ítem por ítem, no habría forma de saber en cuál de esos tres escenarios cayó el estudio.

Referencias Bibliográficas

La numeración es continua con la del Entregable 1 (Revisión de Literatura), que contiene la lista completa de fuentes [1]-[22]. La referencia [23] (Yee & Bailenson) se incorpora en este entregable como soporte del Apartado D.

- [4] Cassell, J., Sullivan, J., Prevost, S., & Churchill, E. (Eds.). (2000). *Embodied conversational agents*. MIT Press.
- [5] Bickmore, T. W., & Picard, R. W. (2005). Establishing and maintaining long-term human-computer relationships. *ACM Transactions on Computer-Human Interaction*, 12(2), 293-327. <https://doi.org/10.1145/1067860.1067867>
- [6] Song, Y., Luximon, A., & Luximon, Y. (2023). Psychological insights into the research and practice of embodied conversational agents, chatbots and social assistive robots: A systematic meta-review. *Behaviour & Information Technology*. <https://doi.org/10.1080/0144929X.2023.2286528>
- [13] Luo, L., Weng, D., Ding, N., Hao, J., & Tu, Z. (2023). The effect of avatar facial expressions on trust building in social virtual reality. *The Visual Computer*, 39(11), 5869-5882. <https://doi.org/10.1007/s00371-022-02700-1>
- [16] Zhang, Y., Liao, Q. V., & Bellamy, R. K. E. (2020). Effect of confidence and explanation on accuracy and trust calibration in AI-assisted decision making. En *Proceedings of the 2020 ACM Conference on Fairness, Accountability, and Transparency* (pp. 295-305). ACM. <https://doi.org/10.1145/3351095.3372852>
- [18] Li, J., Yang, Y., Zhang, R., Liao, Q. V., Song, T., Xu, Z., & Lee, Y. (2024). Understanding the effects of miscalibrated AI confidence on user trust, reliance, and decision efficacy. *arXiv preprint arXiv:2402.07632*. <https://arxiv.org/abs/2402.07632>
- [22] Minge, M., & Thüring, M. (2018). The meCUE questionnaire (2.0): Meeting five basic requirements for lean and standardized UX assessment. En *Design, User Experience, and Usability: Theory and Practice. DUXU 2018. Lecture Notes in Computer Science, vol 10918* (pp. 463-475). Springer. https://doi.org/10.1007/978-3-319-91797-9_33
- [23] Yee, N., & Bailenson, J. (2007). The Proteus effect: The effect of transformed self-representation on behavior. *Human Communication Research*, 33(3), 271-290. <https://doi.org/10.1111/j.1468-2958.2007.00299.x>

Nota de uso de herramientas de IA. Durante la elaboración de este documento se utilizaron herramientas de inteligencia artificial generativa, específicamente ChatGPT (OpenAI) y Claude (Anthropic), como apoyo en tareas de organización de ideas, revisión de redacción y reformulación de párrafos. Todo el contenido, los argumentos, las decisiones de diseño y la selección de fuentes son de autoría propia. Las herramientas se usaron como asistentes de escritura, no como generadores de contenido académico.